

INSTITUTO TECNOLÓGICO Y DE ESTUDIOS SUPERIORES DE
MONTERREY

Actividad Individual
Código de experimentación base con MLflow

Juan Pablo Islas Guzmán

A01797727

OPERACIONES DE APRENDIZAJE AUTOMÁTICO (GPO 10)

**PROFESORES: DR. IVÁN REYES AMEZCUA Y
MTRA. YETNALEZI QUINTAS RUIZ**

6 OCT. 2026

Experimentación con MLflow en un modelo de regresión logística

La actividad convirtió un notebook exploratorio sobre Titanic en un proceso de entrenamiento parametrizable y con seguimiento en MLflow. Se compararon cinco configuraciones de regresión logística mediante accuracy, precision, recall y F1. Entre los resultados reportados, la configuración $C = 1.0$, $\text{max_iter} = 1000$ y $\text{random_state} = 42$ alcanzó un F1 de 0.7970 y se seleccionó como referencia; $C = 10.0$ obtuvo las mismas métricas.

Objetivo y migración del notebook

El notebook se transformó en el script `train.py`, organizado en funciones para cargar los datos, preprocesarlos, construir el modelo, evaluar sus predicciones y registrar los resultados. El notebook original se conservó como material de exploración. Esta organización permite ejecutar nuevas configuraciones desde la terminal sin modificar manualmente las celdas.

El pipeline integra la imputación de valores faltantes, el escalamiento de variables numéricas y la codificación de variables categóricas. Según el procedimiento descrito en el informe original, estas transformaciones se aplican sin fuga de información entre entrenamiento y prueba.

Parametrización y reproducibilidad

El script expone los argumentos `--C`, `--max-iter`, `--test-size` y `--random-state`, todos con valores por defecto. La semilla configura la partición estratificada y se proporciona al modelo; las dependencias se fijan en `requirements.txt`. El ejemplo de ejecución documentado es el siguiente:

```
python train.py --C 1.0 --max-iter 1000  
--test-size 0.2 --random-state 42
```

Nota. El comando se presenta en dos líneas por razones de espacio; se ejecuta como una sola instrucción.

Resultados comparativos

La Tabla 1 reúne las cinco configuraciones y las métricas reportadas en el PDF de la actividad. Los valores se conservan con cuatro decimales para facilitar su comparación.

Tabla 1

Resultados de las configuraciones de regresión logística sobre Titanic

C	max_iter	Semilla	Accuracy	Precision	Recall	F1
0.01	500	42	0.7834	0.8444	0.5846	0.6909
0.1	1000	42	0.8153	0.8000	0.7385	0.7680
1.0	1000	42	0.8280	0.7794	0.8154	0.7970
10.0	1000	42	0.8280	0.7794	0.8154	0.7970
1.0	2000	7	0.8408	0.8846	0.7077	0.7863

Nota. Accuracy representa la exactitud global; precision, la precisión de las predicciones positivas; recall, la sensibilidad; y F1, el equilibrio entre precisión y sensibilidad. Elaboración propia con los resultados de la actividad.

Interpretación de los resultados

Las configuraciones $C = 1.0$ y $C = 10.0$, ambas con $\text{max_iter} = 1000$ y semilla 42, empatan en las cuatro métricas. Se mantiene $C = 1.0$ como configuración de referencia porque aumentar C a 10.0 no aportó una mejora en los resultados reportados. La selección se basa en F1, no únicamente en accuracy.

Con $C = 0.01$ se obtuvo un recall de 0.5846 y un F1 de 0.6909. En la regresión logística, un valor menor de C implica mayor regularización (scikit-learn developers, s. f.). En estas corridas, la configuración con regularización más fuerte registró el menor recall y F1; sin embargo, también empleó un límite de iteraciones diferente.

La configuración con semilla 7 alcanzó el mayor accuracy, 0.8408, y la mayor precision, 0.8846, pero su recall y F1 fueron inferiores a los de la configuración seleccionada. Como también cambió max_iter de 1000 a 2000, la diferencia no puede atribuirse exclusivamente a la semilla.

Seguimiento del experimento y artefactos

Las ejecuciones se agruparon en el experimento TC5061_Titanic_Logistic_Experiments. MLflow Tracking permite asociar parámetros, métricas y archivos de salida a cada corrida para consultarlos posteriormente (MLflow, s. f.). En la actividad se registraron los parámetros y las cuatro métricas de evaluación, además de metrics.json, el reporte de clasificación, la matriz de confusión y el modelo de scikit-learn.

La Figura 1 muestra la lista de corridas del experimento. La Figura 2 presenta la sección de artefactos de logistic_C1_iter1000_seed42, donde se observan classification_report.txt, confusion_matrix.png y metrics.json. Estas evidencias complementan los resultados numéricos de la Tabla 1.

Limitaciones y trabajo posterior

Los resultados corresponden a una partición de entrenamiento y prueba por corrida y a un único algoritmo. La composición de la partición puede modificar las métricas y la configuración seleccionada. Además, algunas comparaciones cambian más de un parámetro a la vez, por lo que no permiten aislar el efecto de cada variable experimental.

Como siguiente paso, se propone aplicar validación cruzada estratificada para comparar las configuraciones con las mismas particiones y evaluar la variabilidad de las métricas. También conviene comparar la regresión logística con árboles o ensambles y reservar un conjunto de prueba independiente para la evaluación final.


Conclusión

La migración a train.py permitió organizar el entrenamiento, exponer su configuración y conservar sus resultados en MLflow. Entre las cinco configuraciones reportadas, $C = 1.0$, $\text{max_iter} = 1000$ y $\text{random_state} = 42$ ofrece el mejor F1, empatado con $C = 10.0$. Esta elección es provisional y debe confirmarse mediante una evaluación con múltiples particiones.

Evidencias del registro en MLflow

Figura 1


Corridas registradas en el experimento de regresión logística



Nota. Captura incluida en el PDF original, recortada para facilitar su lectura. La interfaz muestra seis corridas; la Tabla 1 resume las cinco configuraciones con resultados numéricos reportados.

Figura 2

Artefactos de la corrida logistic_C1_iter1000_seed42



Nota. La captura muestra `classification_report.txt`, `confusion_matrix.png` y `metrics.json` dentro de la pestaña Artifacts. Imagen procedente del PDF original, recortada para concentrar la evidencia visible.

Repositorio del proyecto

El código de la actividad se referencia en el repositorio indicado en el informe original:

https://github.com/Olbap009/TC5061_Experimentacion_MLFlow_IslasGuzmanJuanPablo

Referencias

MLflow. (s. f.). *MLflow Tracking*. <https://mlflow.org/docs/latest/ml/tracking/>

scikit-learn developers. (s. f.). *LogisticRegression*. En *scikit-learn documentation*. https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LogisticRegression.html